

Introduction à Python

Jean-Christophe LOISEAU

Arts & Métiers Institute of Technology, 2021-2022

NumPy : bibliothèque (ou package) pour **Python** destinée à manipuler des **matrices** ou **tableaux multidimensionnels** ainsi que des fonctions mathématiques opérant sur ces tableaux.



Comment calculer $x \cdot y$ avec $x, y \in \mathbb{R}^n$?

$$\boldsymbol{x} \cdot \boldsymbol{y} = \sum_{i=1}^n x_i y_i$$

```
1  def produit_scalaire(x, y):
2
3      # Initialise la variable.
4      z = 0
5
6      # Calcul le produit scalaire.
7      for i in range(len(x)):
8          z = z + x[i] * y[i]
9
10     return z
11
12
```

```
1      In [1]: x, y = npr.rand(100_000), npr.rand(100_000)
```

```
2  
3      In [2]: %%timeit  
4              produit_scalaire(x, y)
```

```
5
```

26.9 ms \pm 110 μ s (mean \pm std. dev. of 7 runs, 100 loops each)

```
1  def produit_scalaire(x, y):  
2      # Calcul le produit scalaire.  
3      return np.sum(x * y)  
4
```

```
1 In [3]: x, y = npr.rand(100_000), npr.rand(100_000)
```

```
2  
3 In [4]: %%timeit  
4         produit_scalaire(x, y)
```

```
5  
  
100  $\mu$ s  $\pm$  1.85  $\mu$ s (mean  $\pm$  std. dev. of 7 runs, 10000 loops each)
```



```
1 In [5]: x, y = npr.rand(100_000), npr.rand(100_000)
```

```
2  
3 In [6]: %%timeit  
4         np.vdot(x, y)      # Produit scalaire en NumPy.  
5
```

25 μ s \pm 8.95 μ s (mean \pm std. dev. of 7 runs, 10000 loops each)

Comment calculer $\|\mathbf{A} - \mathbf{B}\|_2$ avec $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$?

$$\|\mathbf{A} - \mathbf{B}\|_2 = \sqrt{\sum_{i=1}^m \sum_{j=1}^n (A_{ij} - B_{ij})^2}$$

```
1  def distance(A, B):
2      # Taille des tableaux.
3      m, n = A.shape
4
5      # Initialise la variable.
6      d = 0
7
8      # Calcul la distance
9      for i in range(m):
10         for j in range(n):
11             d += (A[i, j] - B[i, j])**2
12
13     return np.sqrt(d)
14
```

```
1 In [7]: A, B = npr.rand(1000, 1000), npr.rand(1000, 1000)
```

```
2  
3 In [8]: %%timeit  
4         distance(A, B)
```

```
5  
  
615 ms  $\pm$  22.3 ms (mean  $\pm$  std. dev. of 7 runs, 1 loop each)
```

```
1  def distance(A, B):  
2      d = np.sum( (A-B)**2 )  
3      return np.sqrt(d)  
4
```

```
1 In [9]: A, B = npr.rand(1000, 1000), npr.rand(1000, 1000)
```

```
2  
3 In [10]: %%timeit  
4         distance(A, B)
```


```
5  
  
4.23 ms  $\pm$  69.3  $\mu$ s (mean  $\pm$  std. dev. of 7 runs, 100 loops each)
```

```
1 In [11]: A, B = npr.rand(1000, 1000), npr.rand(1000, 1000)
```

```
2  
3 In [12]: %%timeit  
4         npl.norm(A-B)      # Definition de la norme en NumPy.  
5
```

2.98 ms \pm 77.1 μ s (mean \pm std. dev. of 7 runs, 100 loops each)

La méthode des moindres-carrés



Comment trouver l'équation de la droite $\hat{y} = ax + b$
qui approxime au mieux les données (x, y) ?

Mesure de l'erreur : Pour des valeurs de a et b données, quelle est l'erreur faite par mon modèle, i.e. à quel point y et \hat{y} sont différents ?

Erreur maximum

$$\max_i |y_i - \hat{y}_i|$$


Erreur absolue moyenne

$$\frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

Erreur quadratique moyenne


$$\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Réduction de l'erreur : Connaissant l'erreur commise par mon modèle pour des valeurs de a et b données, comment dois-je les modifier de façon à réduire cette erreur ?



$$\underset{a,b}{\text{minimiser}} \ \mathcal{L}(a,b)$$

$$\mathcal{L}(a_k + \epsilon) \simeq \mathcal{L}(a_k) + \epsilon \left. \frac{\partial \mathcal{L}}{\partial a} \right|_{a=a_k}$$



Données d'entrée : La fonction $\mathcal{L}(\theta)$ à minimiser, le vecteur initial θ , le pas d'optimisation η , la tolérance ϵ et `maxiter` le nombre maximum d'itérations possibles.

Algorithme : Descente de gradient

1. Evaluer la fonction $\mathcal{L}(\theta)$ et son gradient $\frac{\partial \mathcal{L}}{\partial \theta}$ pour la valeur actuelle de θ .
2. Mettre à jour θ via $\theta = \theta - \eta \frac{\partial \mathcal{L}}{\partial \theta}$.
3. Si $\left\| \frac{\partial \mathcal{L}}{\partial \theta} \right\| \leq \epsilon$, on arrête le calcul, sinon retour à l'étape 1.

Données de sortie : Les paramètres θ du modèle minimisant l'erreur.

Erreur maximum

$$\max_i |y_i - \hat{y}_i|$$

Erreur absolue moyenne

$$\frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

Erreur quadratique moyenne

$$\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Modèle : $\hat{y}_i = ax_i + b$

Erreur : $\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\mathcal{L}(a, b) = \sum_{i=1}^m \mathcal{L}_i(a, b)$$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\mathcal{L}_i(a, b) = \frac{1}{m} (y_i - \hat{y}_i)^2$$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\mathcal{L}_i(a, b) = \frac{1}{m} (y_i - ax_i - b)^2$$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\frac{\partial \mathcal{L}_i}{\partial a} = -\frac{2}{m} (y_i - ax_i - b) x_i$$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\frac{\partial \mathcal{L}_i}{\partial b} = -\frac{2}{m} (y_i - ax_i - b)$$

Modèle :

$$\hat{y}_i = ax_i + b$$

Erreur :

$$\mathcal{L}(a, b) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$\frac{\partial \mathcal{L}}{\partial a} = \sum_{i=1}^m \frac{\partial \mathcal{L}_i}{\partial a}$$

Objectif du TP : Reformuler le code de calcul qui vous est fourni en utilisant au mieux les bonnes pratiques NumPy qui vous ont été présentées.

```
1 In [13]: x, y = donnees_synthetiques()
```

```
2
```

```
3 In [14]: %%timeit
```


```
4         moindres_carres(x, y, eta=0.1)
```

```
5
```

2.98 ms \pm 77.1 μ s (mean \pm std. dev. of 7 runs, 100 loops each)

```
1      In [15]: %%timeit
2                moindres_carres_opt(x, y, eta=0.1)
3
```

2.98 ms \pm 77.1 μ s (mean \pm std. dev. of 7 runs, 100 loops each)





Pour en savoir plus, rendez-vous sur <https://numpy.org/>